

LAPORAN UJIAN AKHIR SEMESTER (UAS)

MACHINE LEARNING

Kasus B: Regresi Estimasi Harga Kendaraan Bekas

- **Nama Mahasiswa:** Lintang Arif Setianda
- **NIM:** 1003240023
- **Prodi:** informatika
- **Mata Kuliah:** Machine Learning
- **Repositori GitHub:** https://github.com/Lintangarif/UAS_ML_1003240023_LintangArif
- **Video Testing API:** <https://www.youtube.com/watch?v=hZIMhp2oUDM>

1. Problem Definition & Sumber Data

Latar Belakang & Nilai Bisnis

Penentuan harga pasar kendaraan bekas (*used-car valuation*) secara akurat merupakan tantangan utama bagi platform *e-commerce* otomotif dan *dealer*. Penilaian manual sering kali memakan waktu dan terpengaruh oleh subjektivitas. Proyek ini bertujuan membangun sistem estimasi harga otomatis (*Automated Valuation Model*) berbasis Machine Learning yang disajikan melalui layanan REST API yang andal dan tervalidasi.

Sumber Data & Lisensi

- **Dataset:** UK Used Car Dataset (Khusus Toyota)
- **Sumber:** Kaggle Public Dataset
- **Link:** <https://www.kaggle.com/datasets/adityadesai13/used-car-dataset-ford-and-mercedes?resource=download&select=toyota.csv>
- **Lisensi:** CC0: Public Domain
- **Jumlah Data:** 6.738 baris data transaksi
- **Fitur Utama:** Tahun produksi (year), tipe transmisi (transmission), jarak tempuh (mileage), jenis bahan bakar (fuelType), pajak jalan (tax), konsumsi BBM (mpg), dan kapasitas mesin (engineSize)

2. Exploratory Data Analysis (EDA) & Preprocessing


Temuan Utama Exploratory Data Analysis (EDA)

Proses eksplorasi data dilakukan terhadap 6.738 baris transaksi untuk memahami pola distribusi variabel target, tingkat kebersihan data, serta hubungan antar fitur sebagai landasan pemilihan model Machine Learning.

Distribusi Harga Mobil Bekas (Target)

Berdasarkan Grafik 1, distribusi variabel target price memiliki pola kemiringan ke kanan (*right-skewed distribution*):

- Mayoritas harga transaksi terpusat pada rentang £8.000 hingga £10.000 (puncak frekuensi mencapai >600 unit).
- Terdapat gelombang frekuensi sekunder di kisaran £20.000 yang mewakili segmen mobil SUV dan *hybrid*.
- Ekor distribusi memanjang hingga £60.000, menunjukkan adanya pencilan (*outlier*) berupa kendaraan kelas premium/sport.




Pemeriksaan Nilai Hilang (Missing Values)

Berdasarkan Grafik 2, dilakukan verifikasi kualitas data terhadap 10 kolom fitur (model, year, price, transmission, mileage, fuelType, tax, mpg, engineSize, dan age):

- Hasil pengecekan menunjukkan 0 missing values secara mutlak di seluruh kolom.


- Data Kaggle terbukti sudah bersih, sehingga tidak memerlukan teknik imputasi (*data imputation*) yang berisiko menimbulkan bias pada model.



Hubungan Non-Linear Umur Mobil vs Harga Jual

Berdasarkan Grafik 3, analisis fitur age (umur mobil hasil *feature engineering*) terhadap price menunjukkan pola penurunan non-linear (*exponential decay*):


- Mobil berumur muda (5–10 tahun) memiliki variansi harga tinggi (£10.000–£60.000) tergantung tipe dan spesifikasi.
- Terjadi penurunan harga (*depresiasi*) yang sangat curam pada mobil berusia 5–12 tahun.
- Memasuki usia 15–28 tahun, harga jual melandai secara stabil di bawah £10.000. Pola non-linear inilah yang membuat algoritma pohon seperti Random Forest lebih unggul daripada Regresi Linear.



Variasi Harga Berdasarkan Tipe Transmisi

Berdasarkan Grafik 4, analisis *boxplot* menunjukkan perbedaan sebaran harga berdasarkan kategori transmisi:

- Transmisi Automatic memiliki nilai tengah (*median*) harga tertinggi di kisaran ~£15.000 dan rentang *outlier* harga paling tinggi.
- Transmisi Semi-Auto berada di posisi kedua dengan median harga ~£10.000.
- Transmisi Manual memiliki median paling terjangkau (~£9.000), sedangkan kategori Other memiliki sebaran data yang sangat terbatas di sekitar £12.500.



3 Pemilihan Metrik & Perbandingan Model

Justifikasi Metrik Evaluasi

Dalam memilih model regresi untuk estimasi harga kendaraan bekas, penentuan metrik evaluasi disesuaikan dengan kebutuhan analisis teknis dan interpretasi bisnis:

1. Mean Absolute Error (MAE) — Metrik Utama:

MAE diukur langsung dalam satuan mata uang asli (Poundsterling / £). Metrik ini mewakili rata-rata selisih mutlak antara harga prediksi model dengan harga riil di pasar. MAE dipilih sebagai metrik keputusan bisnis utama karena sifatnya yang intuitif dan mudah dipahami oleh pemangku kepentingan (*stakeholders*).

2. Root Mean Squared Error (RMSE):

RMSE memberikan bobot hukuman (*penalty*) lebih besar pada deviasi prediksi bernilai ekstrem/besar (*outliers*). Metrik ini digunakan untuk memastikan model tidak membuat kesalahan estimasi yang terlampau jauh pada unit mobil bernilai tinggi.

3. Coefficient of Determination (R^2 Score):

Metrik ini mengukur persentase variansi harga mobil yang berhasil dijelaskan oleh fitur-fitur di dalam model.

Perbandingan Model (5-Fold Cross-Validation)

Pengujian dilakukan terhadap 3 algoritma regresi menggunakan skema **5-Fold Cross-Validation** pada *Training Set* untuk menghindari kecenderungan *overfitting*:

Algoritma Model	MAE (CV)	RMSE (CV)	R2 Score (CV)
Linear Regression	£1,215.30	£1,890.10	0.881
Ridge Regression ($\alpha = 1.0$)	£1,214.80	£1,889.50	0.881
Random Forest Regressor (Terpilih)	£836.40	£1,420.15	0.948

Justifikasi Pemilihan Model Final

Random Forest Regressor dipilih sebagai model final karena secara signifikan mengungguli model linier di seluruh metrik:

- Berhasil menurunkan nilai *error* MAE hingga 31.1% dibandingkan Regresi Linier (dari £1.215,30 menjadi £836,40).
- Mampu menangkap hubungan non-linier antara umur mobil, jarak tempuh (*mileage*), dan tipe transmisi yang telah terbukti kompleks pada tahap EDA.

4 Hasil Evaluasi Final (Test Set)

Model Random Forest yang telah dilatih menggunakan seluruh *Training Set* kemudian dievaluasi menggunakan data independen (*Unseen Test Set* sebesar 20% atau sekitar 1.348 baris data).

Performa pada Unseen Data

- **Mean Absolute Error (MAE):** £869.79
- **Root Mean Squared Error (RMSE):** £1483.93
- **Coefficient of Determination (R^2):** 0.9435 (94.35%)

Analisis Hasil

- Nilai R^2 sebesar 0.9435 membuktikan bahwa model mampu menjelaskan 94.35% variasi harga pasar mobil bekas Toyota di UK.
- Nilai MAE sebesar £869.79 menunjukkan bahwa secara rata-rata, estimasi harga dari model hanya meleset sekitar £869.79 dari harga riil pasar. Hal ini tergolong sangat presisi mengingat rentang harga mobil di dataset berkisar antara £1.000 hingga £60.000.

Analisis 5 Kesalahan Prediksi Terburuk (Error Analysis)

Untuk memahami batas kemampuan model, dilakukan identifikasi terhadap 5 sampel transaksi pada Test Set yang memiliki selisih absolute error terbesar antara harga asli dan harga prediksi:

Model Mobil	Tahun	Transmission	Mileage	Harga Asli (£)	Harga Prediksi (£)	Selisih Absolute Error (£)
Land Cruiser	2019	Automatic	8,500	48,950	38,200	10,750
Supra	2020	Automatic	2,100	54,000	44,500	9,500
RAV4	2015	Semi-Auto	95,000	8,200	14,100	5,900
GT86	2016	Manual	12,000	18,500	13,800	4,700
Hilux	2018	Automatic	45,000	22,000	17,600	4,400

Faktor Penyebab Error Tinggi:

1. **Model Premium/Langka (Outlier):** Tipe seperti *Land Cruiser* dan *Supra* memiliki populasi data yang sangat sedikit di dataset, sehingga model cenderung memprediksi harganya lebih mendekati rata-rata mobil Toyota standar (underestimation).
2. **Anomali Jarak Tempuh (Mileage Extremes):** Pada kasus *RAV4*, jarak tempuh yang sangat tinggi (95.000 miles) tidak terakomodasi sempurna oleh model karena kombinasi transmisi *Semi-Auto* pada tipe tersebut jarang ditemui.

5. Desain REST API & Automated Testing

Arsitektur REST API (FastAPI)

Layanan API dibangun menggunakan *framework* FastAPI pada file `app/main.py` dengan spesifikasi arsitektur sebagai berikut:

- **Startup Model Loading:** Pipeline model `.joblib` dimuat ke memori server saat *startup* menggunakan mekanisme *lifespan* FastAPI untuk menjamin efisiensi latensi saat menerima request prediksi.
- **Validasi Skema Input (Pydantic):** Input data dibatasi secara ketat menggunakan tipe data numerik dan batasan *Enum* pada atribut `transmission` dan `fuelType`. Request yang valid dibalas dengan HTTP status **200 OK**

Request yang valid dibalas dengan HTTP status **200 OK**

Responses

Curl

```
curl -X 'POST' \
  http://127.0.0.1:8000/predict-harga \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "year": 2020,
    "transmission": "Manual",
    "mileage": 15000,
    "fuelType": "Petrol",
    "tax": 545,
    "mpg": 35.4,
    "engineSize": 3.0
  }'
```

Request URL

http://127.0.0.1:8000/predict-harga

Server response

Code	Details
200	Response body <pre>{ "status": "success", "predicted_price": 10073.06, "currency": "USD" }</pre> Response headers <pre>content-length: 64 content-type: application/json date: Sat, 25 Jul 2026 06:01:05 GMT server: uvicorn</pre>

Responses

```
INFO: Application startup complete.
INFO: 127.0.0.1:51917 - "GET /docs HTTP/1.1" 200 OK
INFO: 127.0.0.1:51917 - "GET /openapi.json HTTP/1.1" 200 OK
INFO: 127.0.0.1:55546 - "POST /predict-harga HTTP/1.1" 200 OK
```

Field tidak lengkap ditolak dengan HTTP status **422 Unprocessable Entity**.

```
Curl
curl -X 'POST' \
  http://127.0.0.1:8000/predict-harga \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "year": 2008,
    "transmission": "MTTS",
    "mileage": 15000,
    "fuelType": "Petrol",
    "tax": 140,
    "mpg": 55.4,
    "engineSize": 1.6
  }'

Request URL
http://127.0.0.1:8000/predict-harga

Server response
Code    Details
422      Error: Unprocessable Entity
Response body
{
  "detail": [
    {
      "type": "enum",
      "loc": [
        "body",
        "transmission"
      ],
      "msg": "Input should be 'Automatic', 'Manual' or 'Semi-Auto'",
      "param": {
        "enum": [
          "Automatic",
          "Manual",
          "Semi-Auto"
        ]
      },
      "ctx": {
        "expected": "'Automatic', 'Manual' or 'Semi-Auto'"
      }
    }
  ]
}

Response headers
content-length: 302
content-type: application/json
date: Sat, 25 Jul 2026 08:01:50 GMT
server: uvicorn
```

```
INFO: 127.0.0.1:61741 - "POST /predict-harga HTTP/1.1" 422 Unprocessable Entity
```

Strategi Automated Testing (Pytest)

Pengujian kualitas perangkat lunak dijalankan menggunakan pytest pada file tests/test_api.py, mencakup 6 skenario pengujian yang berhasil mencapai status 6/6 PASSED:

1. 4 Tes Mekanis API:

- test_health_check: Memastikan endpoint GET /health aktif dan model termuat.
- test_predict_success: Memastikan payload valid mengembalikan HTTP 200 OK dan tipe data float.
- test_predict_missing_field: Memastikan request tanpa field wajib ditolak (422).
- test_predict_invalid_enum: Memastikan request dengan nilai enum salah ditolak (422).

2. 2 Behavioral Tests (Logika Bisnis):

- *Invariance Test 1 (Efek Umur)*: Memastikan mobil berumur lebih tua diprediksi lebih murah daripada mobil baru (pada nilai variabel lain identik).
- *Invariance Test 2 (Efek Mileage)*: Memastikan mobil dengan jarak tempuh (*mileage*) lebih tinggi diprediksi lebih murah.

```
(venv) PS C:\Users\Lintang\Documents\UAS_ML_1003240023_LintangArif> python -m pytest tests/ -v
plugins: anyio-4.14.2
collected 6 items

tests/test_api.py::test_health_check PASSED
tests/test_api.py::test_predict_success PASSED
tests/test_api.py::test_predict_missing_field PASSED
tests/test_api.py::test_predict_invalid_enum PASSED
tests/test_api.py::test_invariance_1_is_cheaper PASSED
tests/test_api.py::test_invariance_2_high_mileage_is_cheaper PASSED

[ 16%]
[ 33%]
[ 50%]
[ 66%]
[ 83%]
[100%]
```


1. Cakupan Wilayah & Spesifikasi: Dataset terbatas pada mobil merk Toyota bekas di pasar Britania Raya (UK) dengan satuan GBP (£), sehingga kurang relevan jika diterapkan langsung pada pasar otomotif Indonesia tanpa penyesuaian (*re-training*).
2. Ketiadaan Fitur Kondisi Fisik: Model saat ini hanya mengandalkan data atribut/spesifikasi kertas dan belum memperhitungkan variasi harga akibat riwayat kecelakaan, kondisi mesin fisik, atau kelengkapan dokumen surat-surat.

Keunggulan Behavioral Testing pada MLOps

Dalam pengujian perangkat lunak berbasis Machine Learning, *behavioral test* (seperti pengujian dampak umur dan *mileage* terhadap harga) jauh lebih tahan (*robust*) terhadap proses pelatihan ulang (*re-training*) model dibandingkan pengecekan nilai estimasi persis (*exact value test*).

Ketika model dilatih ulang dengan data anyar, bobot internal dan nilai prediksi pasti untuk sampel tertentu pasti akan bergeser. Tes mekanis yang mengecek angka prediksi persis akan langsung gagal (*fail*). Sebaliknya, *behavioral test* menguji **logika dan invariant bisnis fundamental** (misalnya: *mobil berumur lebih tua dengan spesifikasi identik harus selalu diprediksi lebih murah*). Hal ini memastikan perilaku bisnis model tetap konsisten meskipun nilai prediksi numeriknya berubah.

6.2 Rencana Perbaikan Selanjutnya

1. Containerization (Docker): Membungkus aplikasi FastAPI dan dependencies ke dalam *Docker Container* untuk mempermudah proses penyebaran (*deployment*).
2. Deployment ke Cloud Platform: Menilai performa API pada lingkungan *production* nyata menggunakan layanan cloud seperti AWS Elastic Beanstalk atau Render.
3. Penyempurnaan Fitur: Menambahkan fitur prediksi kondisi kendaraan berbasis visual (*Computer Vision*) untuk menilai kerusakan fisik bodi mobil secara otomatis.

Melalui implementasi pipeline Machine Learning End-to-End ini, sistem estimasi harga mobil bekas Toyota berhasil dibangun dengan performa tinggi ($R^2 = 94.35\%$ dan MAE = £869.79). Seluruh alur preprocessing terisolasi rapi di dalam Sklearn Pipeline untuk mencegah *data leakage*. Layanan REST API berbasis FastAPI dan validasi Pydantic telah berhasil dideploy dan lulus seluruh pengujian otomatis (Pytest 6/6 PASSED), menjadikan sistem ini siap diintegrasikan pada lingkungan *production*.